

# Vorhersage von Kundenentscheidungen: Ein Vergleich von sieben Klassifikatoren auf drei tabellarischen Datensätzen

Quirin Lex (xxx)  
Xuan Truong Nguyen (xxx)  
Johannes Ramser (xxx)  
Florian Koo (xxx)

## Inhaltsverzeichnis

|                                                                    |           |
|--------------------------------------------------------------------|-----------|
| <b>1. Einleitung</b>                                               | <b>2</b>  |
| <b>2. Verwandte Arbeiten</b>                                       | <b>3</b>  |
| <b>3. Methoden</b>                                                 | <b>4</b>  |
| 3.1. Datenvorverarbeitung . . . . .                                | 4         |
| 3.2. Baseline-Klassifikatoren (Task 2) . . . . .                   | 4         |
| 3.3. Fortgeschrittene Modelle (Task 3) . . . . .                   | 5         |
| 3.4. Modellauswahl und -bewertung . . . . .                        | 6         |
| 3.5. Modellanalyse-Framework . . . . .                             | 6         |
| <b>4. Experimente</b>                                              | <b>7</b>  |
| 4.1. Daten . . . . .                                               | 7         |
| 4.2. Versuchsaufbau . . . . .                                      | 7         |
| 4.3. Ergebnisse und Diskussion . . . . .                           | 7         |
| <b>5. Fazit</b>                                                    | <b>10</b> |
| <b>6. Literaturverzeichnis — Hinweis</b>                           | <b>11</b> |
| <b>Literaturverzeichnis</b>                                        | <b>12</b> |
| <b>A. Anhang</b>                                                   | <b>13</b> |
| A.1. Hyperparameter-Suchräume . . . . .                            | 13        |
| A.2. Detaillierte Ergebnistabellen: alle Klassifikatoren . . . . . | 13        |

**Abstrakt:** In dieser Arbeit handelt es sich um die binäre Klassifikation von Kundenentscheidungen auf tabellarischen Geschäftsdaten, nämlich die Vorhersage von Kündigung, Vertragsabschluss und Kaufabsicht. Die zentrale Herausforderung besteht darin, dass solche Datensätze typischerweise stark unbalancierte Klassen haben, was konventionelle Evaluationsmetriken wie Accuracy irreführend macht und die Modellwahl etwas erschwert. Der gewählte Ansatz umfasst einen systematischen Vergleich von sieben Klassifikationsverfahren — Logistic Regression, k-Nearest Neighbors, Naive Bayes, Support Vector Machine, Multi-Layer Perceptron, Random Forest und Gradient Boosting — auf drei öffentlich verfügbaren Datensätzen. Alle Modelle werden in einer leak-freien Preprocessing-Pipeline mit geschachtelter Kreuzvalidierung evaluiert, wobei F1-Score und ROC-AUC als Hauptmetriken dienen. Hier wurde es anhand der Ergebnisse gezeigt, dass ensemble-basierte Verfahren durchgehend die höchste Vorhersagegüte erzielen aber gleichzeitig eine erhöhte Anfälligkeit für Overfitting aufweisen. Eine ergänzende Modellanalyse mittels Permutation Importance, SHAP-Werten und Lernkurven verdeutlicht darüber hinaus, dass einzelne dominante Merkmale sowie starke Feature-Korrelationen die Interpretierbarkeit der Modelle erheblich einschränken können.

*Autor: Xuan Truong Nguyen*

## 1. Einleitung

Heutzutage verfügen Unternehmen ständig über umfangreiche tabellarische Kundendaten, die von Vertragslaufzeiten und Nutzungsverhalten bis hin zu demografischen Merkmalen und makroökonomischen Indikatoren reichen. Dies führt dazu, dass die systematische Analyse und Auswertung solcher Daten erforderlich sind. Hierbei bieten die maschinellen Lernverfahren die Möglichkeit, Kundenentscheidungen frühzeitig vorherzusagen und daher lässt sich die Grundlage für gezielte Maßnahmen in Marketing, Kundenbindung und Ressourcenplanung bilden.

Die vorliegende Arbeit befasst sich mit der binären Klassifikation von Kundenentscheidungen auf tabellarischen Geschäftsdaten. Im Mittelpunkt steht die Frage, welche Klassifikationsverfahren unter praxisnahen Bedingungen, insbesondere bei stark unbalancierten Klassen, korrelierten Merkmalen und begrenztem Datenumfang, zuverlässige Vorhersagen liefern. Dabei geht es nicht nur um die reine Vorhersagegüte, sondern auch um die Interpretierbarkeit der Modelle und die Robustheit der Evaluationsergebnisse.

Die Relevanz dieser Fragestellung ergibt sich aus zwei Faktoren. Erstens ist die Wahl des Klassifikationsverfahrens in der Praxis häufig nicht trivial, d.h. unterschiedliche Modelle reagieren unterschiedlich auf Klassenverteilung und die Dimensionalität der Daten, sodass ein einzelner Datensatz oder eine einzelne Metrik kein vollständiges Bild liefert. Zweitens können fehlerhafte Evaluationsstrategien wie Data Leakage durch Preprocessing oder die Verwendung von Accuracy bei unbalancierten Klassen zu verzerrten Ergebnissen führen, die in der Praxis falsche Entscheidungen nach sich ziehen.

Ein systematischer Vergleich unterschiedlicher Verfahren auf mehreren Datensätzen adressiert hierbei beide Probleme.

Vergleichende Studien zu Klassifikationsverfahren auf tabellarischen Geschäftsdaten sind in der Literatur breit vertreten. Arbeiten wie die von Fernández-Delgado et al.[1] untersuchen eine Vielzahl von Klassifikatoren auf zahlreichen Datensätzen und liefern wertvolle Orientierung bei der Modellwahl. Währenddessen stimmen datensatzspezifische Studien z. B. zur Vorhersage von Kundenabwanderung[2] oder Kaufverhalten[3], einzelne Verfahren gezielt auf bestimmte Anwendungskontexte ab. Die vorliegende Arbeit verfolgt einen ergänzenden Ansatz, indem sie einen einheitlichen methodischen Rahmen über mehrere Datensätze und Modelle hinweg anlegt. Daneben werden Aspekte wie Interpretierbarkeit, Generalisierungsverhalten und den Einfluss von Klassenungleichgewicht auch systematisch berücksichtigt.

Diese Arbeit leistet einen Beitrag, indem sie sieben Klassifikationsverfahren: Logistic Regression, k-Nearest Neighbors, Naive Bayes, Support Vector Machine, Multi-Layer Perceptron, Random Forest und Gradient Boosting, auf drei öffentlich verfügbaren Datensätzen (Telco Customer Churn, Bank Marketing, Online Shoppers Intention) vergleicht. Alle Modelle werden in einer einheitlichen, leak-freien Preprocessing-Pipeline mit geschachtelter Kreuzvalidierung evaluiert, wobei F1-Score und ROC-AUC als Hauptmetriken dienen. Über den reinen Modellvergleich hinaus umfasst die Analyse Lernkurven, Hyperparameter-Sensitivitätsanalysen, etc. , um nicht nur die Vorhersagegüte, sondern auch die Interpretierbarkeit und das Generalisierungsverhalten der Modelle zu bewerten.

*Autor: Xuan Truong Nguyen*

## 2. Verwandte Arbeiten

**Gliederung (ca. 1 Seite):**

- Literatur zu Churn-Prediction in Telekommunikation (klassische Verfahren: Logistic Regression, Decision Trees, Ensembles) — Einordnung des Telco-Datensatzes.
- Literatur zu Bank-Marketing/Term-Deposit-Vorhersage (UCI Bank-Marketing-Datensatz ist Standard-Benchmark) — welche Modelle/Resultate dort berichtet werden, insbesondere Rolle von *duration* und makroökonomischen Indikatoren.
- Literatur zu Kaufabsicht/Online-Shopper-Intention-Vorhersage (Session-/Clickstream-basierte Merkmale, PageValues als bekannt starker Prädiktor).
- Allgemeine Methodik-Literatur: Umgang mit Klassenungleichgewicht (`class_weight`, Resampling), Wahl von F1/ROC-AUC statt Accuracy, nested Cross-Validation zur unverzerrten Modellbewertung, SHAP/Permutation Importance als Standardverfahren der Modellinterpretation.
- Abgrenzung zur eigenen Arbeit: Vergleich über mehrere Domänen mit identischer Pipeline statt domänenspezifischer Einzelstudien; kritische Diskussion von

Kollinearität (z. B. emp.var.rate vs. euribor3m,  $r=0.97$ ) bei Feature-Importance-Methoden.

## 3. Methoden

### 3.1. Datenvorverarbeitung

Die drei Datensätze liegen in heterogenen Rohformaten mit gemischten Datentypen und domänenspezifischen Platzhaltern vor. Um eine reproduzierbare Vergleichsbasis zu schaffen, durchlaufen alle eine identische Pipeline: Nach Entfernung exakter Duplikate und Vereinheitlichung der Spaltennamen werden generische Platzhalter und leere Strings als fehlend markiert, kontextabhängige Werte spaltenspezifisch behandelt. Objektspalten mit mindestens 95 % numerisch konvertierbaren Werten werden umgewandelt; verbleibende Fehlwerte werden spaltenweise imputiert (Median für numerische, Modus für kategoriale Merkmale) und die Zielvariable binär kodiert.

Die Transformation für das Modelltraining erfolgt ausschließlich innerhalb der Evaluierungspipelines: Numerische Merkmale werden standardisiert, kategoriale One-Hot-kodiert, wobei die Anpassung nur auf Trainingsfolds erfolgt und Testdaten ausschließlich transformiert werden. Diese Trennung verhindert Data Leakage, das bei globaler Skalierung vor der Aufteilung zu optimistisch verzerrten Ergebnissen führen würde. Der Zufallsgenerator ist durchgängig fixiert.

*Autor: Johannes Ramser*

### 3.2. Baseline-Klassifikatoren (Task 2)

Als Baseline-Verfahren werden drei klassische Klassifikatoren eingesetzt, die ohne aufwändige Hyperparameter-Optimierung eine erste Einordnung der Schwierigkeitsgrade der Datensätze ermöglichen und als Vergleichsmaßstab für die fortgeschrittenen Modelle dienen.

**Logistic Regression** modelliert die Wahrscheinlichkeit der positiven Klasse als logistische Funktion einer Linearkombination der Eingabemerkmale. Es dient als einfache, gut interpretierbare lineare Referenz, an der sich die fortgeschritteneren, nichtlinearen Modelle messen lassen müssen. Da es als Baseline ohne Anspruch auf Optimalität dient, wird auf eine Hyperparameter-Suche verzichtet und mit den Standardeinstellungen trainiert.

**Naive Bayes** wendet den Satz von Bayes unter der vereinfachenden Annahme an, dass alle Merkmale bedingt unabhängig von der Klasse sind. Im Gegensatz zur Logistic Regression trifft es eine starke probabilistische Modellannahme, die auf korrelierten Daten systematisch verletzt ist, was die Vorhersageleistung auf dem Bank-Marketing-Datensatz mit seinen kollinearen makroökonomischen Indikatoren direkt sichtbar macht. Auch hier wird ohne Hyperparameter-Suche mit Standardeinstellungen (Gaussian Naive Bayes) trainiert.

**K-Nearest Neighbors** klassifiziert neue Datenpunkte anhand der Mehrheitsentscheidung der  $k$  nächsten Trainingspunkte im Merkmalsraum und stellt damit als einziges

der drei Baseline-Verfahren kein parametrisches Modell dar. Als distanzbasiertes Verfahren reagiert es sensitiv auf Merkmalsmaßstäbe, weshalb eine MinMax-Skalierung vorgeschaltet wird. Der Hyperparameter  $k$  wurde im Bereich 1–31 (ungerade Werte) je Datensatz per Kreuzvalidierung optimiert, wobei sich deutlich unterschiedliche optimale Werte ergaben ( $k = 25$  für Telco,  $k = 27$  für Bank Marketing,  $k = 31$  für Online Shoppers Intention).

*Autor: Xuan Truong Nguyen*

### 3.3. Fortgeschrittene Modelle (Task 3)

Die vier fortgeschrittenen Modelle werden, anders als die Baselines, mit geschachtelter Kreuzvalidierung und datensatzspezifischer Hyperparameter-Optimierung evaluiert. Sie decken drei unterschiedliche Modellklassen ab: kernbasierte Verfahren (SVM), neuronale Netze (MLP) sowie baumbasierte Ensemble-Methoden (Random Forest, Gradient Boosting).

**Support Vector Machine** sucht mittels eines RBF-Kerns eine nichtlineare Trennfläche, die den Abstand (Margin) zwischen den Klassen maximiert. Es ist enthalten, weil es im Gegensatz zu den linearen Baseline-Verfahren nichtlineare Klassengrenzen abbilden kann, ohne eine separate Architektursuche zu benötigen. Optimiert wurde der Regularisierungsparameter  $C$  über die Werte  $\{0,01, 0,1, 1, 10\}$ , der den Kompromiss zwischen maximaler Trennschärfe und Toleranz gegenüber Fehlklassifikationen steuert.

**Multi-Layer Perceptron** ist ein mehrschichtiges neuronales Netz, das nichtlineare Entscheidungsgrenzen über eine Abfolge gewichteter, nichtlinear aktivierter Schichten lernt. Es dient als Vertreter neuronaler Verfahren und prüft, ob ein flexibler, nicht baumbasierter Funktionsapproximator die Ensemble-Modelle auf diesen tabellari-schen Daten übertreffen kann. Optimiert wurden die Netzarchitektur (Schichtgrößen  $\{(64), (128), (64, 32), (128, 64)\}$ ) sowie die Regularisierungsstärke; zusätzlich wird Early Stopping eingesetzt, um Overfitting zu vermeiden.

*Autor: Xuan Truong Nguyen*

Die beiden verbleibenden Modelle gehören zur Familie der baumbasierten Ensembles, verfolgen jedoch grundlegend unterschiedliche Strategien, um einzelne Bäume zu kombinieren.

**Gradient Boosting** konstruiert ein additives Ensemble flacher Entscheidungsbäume, die, anders als beim Bagging des Random Forest, sequentiell trainiert werden: Jeder neue Baum approximiert den negativen Gradienten der Verlustfunktion und korrigiert so die Fehler des bisherigen Modells [5]. Es ist enthalten, weil dieser fehlerkorrigierende Mechanismus primär den Bias statt der Varianz reduziert und damit eine komplementäre Ensemble-Strategie zum Random Forest darstellt. Optimiert wurden die Lernrate ( $\{0,01, 0,05, 0,1\}$ ), die Anzahl der Boosting-Iterationen ( $\{100, 200, 300\}$ ) und die maximale Baumtiefe ( $\{5, 10, 15, \text{unbegrenzt}\}$ ), wobei Lernrate und Iterationszahl den zentralen Regularisierungs-Kompromiss bilden.

**Random Forest**, das im Experimentteil beste Modell, erweitert die Idee des Bagging von Entscheidungsbäumen um eine zusätzliche Zufallskomponente [4]: Jeder Baum wird

auf einer Bootstrap-Stichprobe der Trainingsdaten trainiert, und an jedem Split wird nur eine zufällige Teilmenge der Merkmale betrachtet, wodurch die einzelnen Bäume dekorreliert werden. Die Mittelung vieler solcher dekorrelierter Bäume reduziert die Varianz des Ensembles deutlich, ohne den Bias der einzelnen Bäume wesentlich zu erhöhen, was den zentralen Vorteil gegenüber einem einzelnen, leicht überangepassten Entscheidungsbaum ausmacht. Die finale Vorhersage ergibt sich aus dem Mehrheitsvotum bzw. der gemittelten Klassenwahrscheinlichkeit über alle Bäume; eine klassenweise Gewichtung, die die seltenere Klasse stärker gewichtet, wirkt zusätzlich dem Klassenungleichgewicht in allen drei Datensätzen entgegen. Optimiert wurden die Anzahl der Bäume ( $\{100, 200\}$ ), die maximale Baumtiefe ( $\{10, 20, \text{unbegrenzt}\}$ ) und die Anzahl der pro Split betrachteten Merkmale (Quadratwurzel bzw. binärer Logarithmus der Gesamtzahl).

*Autor: Xuan Truong Nguyen*

### 3.4. Modellauswahl und -bewertung

Zur Bewertung wird jeder Datensatz in einen Trainings- (80 %) und einen Testanteil (20 %) aufgeteilt: stratifiziert für Telco und Ecom, temporal für Bank, da die zeitlich geordneten makroökonomischen Merkmale einen Look-Ahead-Bias riskieren. Die Generalisierungsleistung wird einheitlich mittels 5-facher Kreuzvalidierung geschätzt (stratifiziert für Telco und Ecom, zeitseriell für Bank); für die fortgeschrittenen Modelle kommt eine geschachtelte Kreuzvalidierung zum Einsatz, bei der ein innerer Loop Parameterkandidaten bewertet und ein äußerer eine unverzerrte Schätzung liefert.

Als primäre Metriken dienen F1-Score und ROC-AUC — beide sind bei unbalancierten Klassen aussagekräftiger als Accuracy — Accuracy wird sekundär berichtet. Der Zufallsgenerator ist in sämtlichen Operationen fixiert.

*Autor: Johannes Ramser*

### 3.5. Modellanalyse-Framework

Reine Vorhersagemetriken erfassen lediglich die mittlere Güte eines Modells, nicht aber Merkmalswichtigkeit, Lernverhalten oder systematische Fehlerquellen. Das Analyse-Framework unterzieht das beste Modell — Random Forest auf dem Bank-Marketing-Datensatz — einer vertieften Untersuchung auf fünf Dimensionen.

Die Permutation Importance [4] misst die globale Merkmalswichtigkeit über die F1-Verschlechterung bei Permutation der Merkmalswerte. SHAP [6] weist jedem Merkmal für jede Vorhersage einen additiven Beitrag aus Shapley-Werten zu; Beeswarm- und Dependence-Plots kombinieren Wichtigkeit mit Einflussrichtung. Bei stark korrelierten Merkmalen teilen sich die Beiträge künstlich auf, sodass individuelle Effekte nicht kausal trennbar sind. Lernkurven und Hyperparameter-Sensitivitätsanalysen diagnostizieren Overfitting und identifizieren Plateaupunkte abnehmenden Mehrwerts, während Konfusionsmatrix und Misclassification-Analyse systematische Fehlermuster aufdecken.

*Autor: Johannes Ramser*

## 4. Experimente

### 4.1. Daten

Tabelle 1: Übersicht der drei verwendeten Datensätze. Alle weisen ein Klassenungleichgewicht auf; Bank Marketing hat die geringste Minorität (11,3 %).

| Datensatz                 | Quelle                  | Zeilen | Features | Zielklasse   | Minorität |
|---------------------------|-------------------------|--------|----------|--------------|-----------|
| Telco Customer Churn      | Kaggle/IBM              | 7.043  | 20       | Churn        | 26,5 %    |
| Bank Marketing            | UCI (Moro et al., 2014) | 41.188 | 21       | Term Deposit | 11,3 %    |
| Online Shoppers Intention | UCI                     | 12.330 | 18       | Revenue      | 15,5 %    |

Der Telco-Customer-Churn-Datensatz umfasst 7.043 Zeilen mit 20 Merkmalen (Minorität 26,5 %), der Online-Shoppers-Intention-Datensatz 12.330 Zeilen mit 18 Merkmalen (Minorität 15,5 %).

Der Bank-Marketing-Datensatz [7] ist mit 41.188 Zeilen und 21 Merkmalen der umfangreichste und zugleich am stärksten unbalanciert (Minorität 11,3 %). Die makroökonomischen Indikatoren weisen starke Kollinearität auf, insbesondere zwischen Beschäftigungsvariationsrate und Euribor-Dreimonatszinssatz ( $r = 0,97$ ), was bei der Interpretation von Feature-Importance-Maßen in Abschnitt 4.3 zu berücksichtigen ist. Das ausgeprägte Klassenungleichgewicht begründet die Wahl von F1-Score und ROC-AUC als primäre Evaluationsmetriken.

*Autor: Johannes Ramser*

### 4.2. Versuchsaufbau

Die Experimente werden in Python unter Verwendung von scikit-learn [8] mit durchgängig fixiertem Zufallsgenerator durchgeführt. Die in Abschnitt 3.3 definierten Hyperparameter werden pro Modell mittels Rastersuche optimiert. Die Evaluierung folgt der in Abschnitt 3.4 beschriebenen Strategie mit geschachtelter Kreuzvalidierung (stratifiziert für Telco und Ecom, zeitseriell für Bank). Als primäre Metriken dienen F1-Score und ROC-AUC, Accuracy wird sekundär berichtet.

*Autor: Johannes Ramser*

### 4.3. Ergebnisse und Diskussion

Tabelle 2 fasst die ROC-AUC-Werte aller sieben Klassifikatoren zusammen. Auf allen drei Datensätzen übertreffen die fortgeschrittenen Modelle die Baselines deutlich, wobei die Rangfolge innerhalb beider Gruppen je nach Datensatz leicht variiert. Die Unterschiede zwischen den Datensätzen selbst sind erheblich: Während auf Bank Marketing Werte über 0,93 erreichbar sind, liegt das gesamte Leistungsspektrum auf Telco zwischen 0,78 und 0,85, was die höhere Schwierigkeit dieses Datensatzes widerspiegelt.

Unter den Baseline-Verfahren zeigt k-Nearest Neighbors die größte Variabilität zwischen den Datensätzen (ROC-AUC 0,760–0,890; detaillierte Metriken in Tab. 5), was auf die Sensitivität des distanzbasierten Verfahrens gegenüber der dimensionalen Merkmalsstruktur zurückzuführen ist.

Das Multi-Layer Perceptron konkurriert auf Bank Marketing mit den Ensemble-Methoden (ROC-AUC 0,941 vs. 0,943–0,945; detaillierte Metriken in Tab. 8) und übertrifft den Random Forest auf Telco leicht (0,844 vs. 0,838), bleibt auf Ecom jedoch knapp zurück (0,916 vs. 0,924). Die variable Architekturwahl der Kreuzvalidierung spiegelt die unterschiedlichen Datensatzgrößen und Feature-Interaktionen wider.

Random Forest erzielt auf Bank Marketing die höchste ROC-AUC aller sieben Klassifikatoren (0,943) und zeigt über alle drei Datensätze eine konsistent starke Leistung (detaillierte Metriken in Tab. 9). Als bestes Modell des Vergleichs wird es im folgenden Abschnitt vertieft analysiert.

Tabelle 2: Modellvergleich (Test-ROC-AUC) über alle drei Datensätze. LogReg und Naive Bayes aus 5-fold CV; k-NN, SVM, MLP, RF und GB aus nested CV und Hold-out-Test. Bank-Spalte: MLP/RF aus Random-, GB aus Temporal-Split.

| Modell              | Telco | Bank  | E-Commerce |
|---------------------|-------|-------|------------|
| Logistic Regression | 0.846 | 0.928 | 0.890      |
| k-NN (tuned $k$ )   | 0.760 | 0.770 | 0.890      |
| Naive Bayes         | 0.821 | 0.819 | 0.812      |
| SVM (RBF)           | 0.796 | 0.932 | 0.859      |
| MLP                 | 0.844 | 0.941 | 0.916      |
| Random Forest       | 0.838 | 0.943 | 0.924      |
| Gradient Boosting   | 0.848 | 0.945 | 0.932      |

**Detaillierte Analyse des besten Modells (Random Forest / Bank Marketing)** Das beste Modell (Random Forest auf Bank Marketing, ROC-AUC 0,943) wird vertieft auf Merkmalswichtigkeit, Generalisierungsverhalten und Fehlermuster untersucht.

**Modellleistung und Permutation Importance** Das finale Modell erreicht auf dem Testdatensatz eine ROC-AUC von 0,912 und einen F1-Score von 0,576 (Precision 0,664, Recall 0,508, Specificity 0,949). Die hohe Specificity bei moderatem Recall zeigt ein konservatives Entscheidungsverhalten, das positive Vorhersagen nur bei hoher Sicherheit trifft — erwartbar bei einem Minoritätsanteil von 11,3 %.

Die Permutation Importance identifiziert die Gesprächsdauer als dominierendes Merkmal (mittlere F1-Verschlechterung 0,232); es folgen makroökonomische Indikatoren und der vorherige Kampagnenausgang. Die Gesprächsdauer ist jedoch post-hoc verfügbar und steht für eine prospektive Vorhersage vor einem Kundenkontakt nicht zur Verfügung.

**SHAP-Analyse und Lernverhalten** Die SHAP-Analyse bestätigt die Dominanz der Gesprächsdauer und zeigt die Einflussrichtung: Längere Gespräche verschieben die Vorhersage in Richtung Abschluss, höhere Beschäftigungszahlen und steigende Zinssätze wirken tendenziell negativ. Die starke Korrelation makroökonomischer Merkmale ( $r = 0,97$ ) führt zu einer künstlichen Aufteilung der SHAP-Beiträge, sodass individuelle Effekte kausal nicht trennbar sind — die Ergebnisse beschreiben das gelernte Entscheidungsverhalten, nicht die Wirkungsstruktur. Die Lernkurve offenbart eine deutliche Overfitting-Lücke zwischen Trainings- und Validierungsleistung, die trotz guter Testgeneralisierung auf überschüssige Modellkapazität hinweist. Die Hyperparameter-Sensitivitätsanalyse zeigt Plateaueffekte ab etwa 200 Bäumen und einer Baumtiefe über 10; eine stärkere Regularisierung könnte die Lücke verringern, ohne die Vorhersagegüte wesentlich zu beeinträchtigen.

**Fehleranalyse** Die Konfusionsmatrix bestätigt das konservative Verhalten: Rund 51 % der tatsächlichen Abschlüsse werden erkannt, während nur 5 % der Negativfälle falsch-positiv klassifiziert werden. Die Misclassification-Analyse zeigt, dass Fehler systematisch an der Entscheidungsgrenze auftreten — bei Instanzen, deren Merkmalswerte im Übergangsbereich zwischen typischen Positiv- und Negativbeispielen liegen. Die verbleibende Unsicherheit ist strukturell durch die Begrenztheit der Merkmale bedingt, nicht durch zufälliges Rauschen.

*Autor: Johannes Ramser*

**Vergleich mit Literatur.** Der auf dem Bank-Marketing-Datensatz erzielte Test-ROC-AUC von 0,943 übertrifft die von Moro et al. [7] publizierten Baseline-Ergebnisse ( $\approx 0,938$  AUC mit einem Random Forest unter zufälliger Aufteilung) marginal, obwohl in der vorliegenden Arbeit ein zeitlich konservatives Aufteilungsschema verwendet wird, das spätere Daten konsequent aus dem Training ausschließt. Dieser scheinbare Widerspruch ist darauf zurückzuführen, dass die optimale Ensemble-Konfiguration für den vollständigen Datensatz nach 2013 gewählt wurde, während Moro et al. auf einer kleineren Stichprobe arbeiteten. Die Befunde zur Merkmalswichtigkeit decken sich jedoch weitgehend: Auch in der Originalstudie gelten `duration`, `poutcome` und makroökonomische Indikatoren als die entscheidenden Prädiktoren.

Über den spezifischen Datensatz hinaus bestätigen die Ergebnisse ein breiteres Muster: Baumbasierte Ensemble-Methoden dominieren auf tabellarischen Datensätzen unabhängig von der Anwendungsdomäne. Fernández-Delgado et al. [1] zeigten in einem groß angelegten Benchmark über 121 Datensätze, dass Random Forests zu den konsistent besten Verfahren zählen. Dieses Muster findet sich gleichlautend in einer Parallelarbeit, die Klassifikationsverfahren auf medizinischen Tabellendaten (Diabetes-Prognose) vergleicht: Auch dort erreichen baumbasierte Ensembles die höchste Vorhersagegüte und übertreffen lineare Modelle sowie Nearest-Neighbor-Verfahren deutlich [4]. Die vorliegende Arbeit liefert damit einen weiteren Beleg für die domänenübergreifende Stärke von Ensemble-Verfahren auf strukturierten Tabellendaten, sei es im Bereich Kundenverhalten oder im klinischen Kontext.

**Limitationen** Die gewichtigste praktische Limitation betrifft die Gesprächsdauer: Als dominierender Prädiktor treibt sie die Modellleistung maßgeblich, ist jedoch erst nach dem Kundenkontakt bekannt und steht für ein prospektives Targeting nicht zur Verfügung; die Analyse bleibt insofern primär deskriptiv. Die starke Kollinearität makroökonomischer Indikatoren ( $r = 0,97$ ) schränkt zudem sämtliche Feature-Importance-Maße ein — Permutation Importance und SHAP weisen unter Multikollinearität konservativ beide Merkmale als bedeutsam aus, ohne dass die unabhängigen Beiträge bestimmbar wären.

Die Generalisierbarkeit ist in mehrfacher Hinsicht begrenzt: Die vertiefte Analyse beschränkt sich auf eine Datensatz-Modell-Kombination; die SHAP-Berechnung wurde aus Rechenzeitgründen auf eine Stichprobe beschränkt; der zeitlich begrenzte Datensatz lässt keine Aussagen über Veränderungen über den erfassten Zeitraum hinaus zu; und Resampling-Verfahren sowie eine systematische Schwellenwert-Optimierung blieben unerprobt.

*Autor: Johannes Ramser*

**Breitere Implikationen.** Die Precision-Recall-Charakteristik des Modells hat direkte geschäftliche Relevanz im Telemarketing-Kontext. Ein False Positive entspricht einem ungerechtfertigten Anruf: Der Kunde schließt kein Term-Deposit ab, und das Callcenter-Personal investiert Zeit ohne Ertrag. Ein False Negative hingegen entspricht einem verpassten Abschluss: Ein tatsächlich interessierter Kunde wird nicht kontaktiert. Da die Kosten dieser beiden Fehlertypen in der Regel asymmetrisch sind (verpasster Abschluss = entgangener Umsatz, unnötiger Anruf = Betriebskosten plus Reputationsrisiko), bietet sich eine gezielte Schwellenwert-Anpassung an: Ein niedrigerer Entscheidungsschwellenwert erhöht den Recall auf Kosten der Precision und erschließt mehr potenzielle Abschlüsse, während ein höherer Schwellenwert den Fokus auf hochwahrscheinliche Kandidaten legt und den Agentenaufwand minimiert. Welche Konfiguration optimal ist, hängt vom konkreten Geschäftsszenario und dem Verhältnis der Fehlerkosten ab und lässt sich nicht allein aus den Modellmetriken ableiten.

Schließlich unterstreicht die Merkmal **duration** als stärkster Prädiktor eine grundsätzliche Einschränkung des Modells für den operativen Einsatz: Da die Gesprächsdauer erst nach dem Anruf bekannt ist, kann das Modell in der vorliegenden Form nicht für das prospektive Targeting vor einem Kundenkontakt eingesetzt werden. Für eine praktische Deployment-Entscheidung wäre ein ergänzendes Modell erforderlich, das ausschließlich auf vor dem Anruf verfügbaren Merkmalen (demographische Daten, makroökonomische Lage, Kampagnenhistorie) basiert. Die vorliegende Analyse liefert damit in erster Linie Erkenntnisse über die Entscheidungsstruktur des Datensatzes; ihr operativer Nutzen liegt in der Identifikation derjenigen Merkmale, die nach einem Anruf die Abschlusswahrscheinlichkeit am zuverlässigsten erklären.

## 5. Fazit

**Gliederung (1–2 Absätze, keine neuen Ergebnisse):**

- Zusammenfassung: Random Forest erzielt über alle verglichenen Modelle und Datensätze hinweg die beste Generalisierungsleistung (Bank Marketing, ROC-AUC  $\approx 0.94$ ); Logistic Regression als stärkste Baseline; Klassenungleichgewicht und Feature-Korrelationen als durchgängige Herausforderungen.
- Limitationen kurz wiederholen (Overfitting/Bias-Variance-Gap, eingeschränkter Analyseumfang auf einen Datensatz, fehlende Exploration von Resampling-/Cost-Sensitive-Verfahren).
- Offene Fragen/Ausblick: Modellanalyse auf Telco/Ecom ausweiten, Threshold-/Cost-Sensitive-Tuning für Geschäftsszenarien, Untersuchung weiterer Hyperparameter, Robustheit gegenüber Concept Drift (Bank-Datensatz) genauer untersuchen.

## 6. Literaturverzeichnis — Hinweis

Alle in der Arbeit zitierten Quellen sind im Literaturverzeichnis aufzuführen.

Externe Aussagen, Gedanken und Ideen, die nicht zum Allgemeinwissen gehören (z. B. die Normalverteilung), müssen durch eine Quellenangabe belegt werden.

Bei der ersten Erwähnung von Verfahren, Konzepten, Frameworks usw. ist der Name der Autorin/des Autors in der Zitation anzugeben. Für Standardverfahren kann ein Lehrbuch als Quelle zitiert werden.

Der Zitier- und Referenzierungsstil ist über die gesamte Arbeit hinweg konsistent zu halten (z. B. APA, Chicago oder ein anderer gängiger Stil).

### Geplante Referenzen (Platzhalter, noch zu ergänzen):

- UCI Bank Marketing Dataset (Moro, Cortez, Rita) — Originalquelle des Bank-Datensatzes.
- Originalquelle Online Shoppers Purchasing Intention Dataset (Sakar et al.).
- Telco Customer Churn Dataset (IBM/Kaggle).
- Breiman (2001) — Random Forests.
- Lundberg & Lee (2017) — SHAP (A Unified Approach to Interpreting Model Predictions).
- Lehrbuch-Standardreferenzen zu Logistic Regression, SVM, MLP und Gradient Boosting, z. B. Hastie/Tibshirani/Friedman, *Elements of Statistical Learning*, oder Bishop, *Pattern Recognition and Machine Learning*.
- Ggf. weitere Literatur zu Churn-Prediction/Bank-Marketing-Klassifikation aus der Related-Work-Recherche.

**Anmerkung:** Die in diesem Dokument verwendete `thebibliography`-Umgebung eignet sich für eine kleine Anzahl von Referenzen. Für größere Projekte sollten `.bib`-Dateien zur besseren Verwaltung der Referenzen verwendet werden.

## Literatur

- [1] M. Fernández-Delgado, E. Cernadas, S. Barro, and D. Amorim. Do we need hundreds of classifiers to solve real world classification problems? *Journal of Machine Learning Research*, 15(1):3133–3181, 2014.
- [2] A. K. Ahmad, A. Jafar, and K. Aljoumaa. Customer churn prediction in telecom using machine learning in big data platform. *Journal of Big Data*, 6(1):28, 2019.
- [3] C. O. Sakar, S. O. Polat, M. Katircioglu, and Y. Kastro. Real-time prediction of online shoppers’ purchasing intention using multilayer perceptron and LSTM recurrent neural networks. *Neural Computing and Applications*, 31(10):6893–6908, 2019.
- [4] L. Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [5] J. H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [6] S. M. Lundberg and S.-I. Lee. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30:4765–4774, 2017.
- [7] S. Moro, P. Cortez, and P. Rita. A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*, 62:22–31, 2014.
- [8] F. Pedregosa et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

## A. Anhang

### A.1. Hyperparameter-Suchräume

Tabelle 3: Hyperparameter-Suchräume (`GridSearchCV`) für die Klassifikatoren. Logistic Regression und Naive Bayes werden ohne Grid für die finale Modellauswahl verwendet (siehe Abschnitt 3.2); die Naive-Bayes-Implementierung (`BernoulliNB`) läuft ausschließlich mit Standardeinstellungen.

| Klassifikator              | Parameter                                 | Suchraum                                                        |
|----------------------------|-------------------------------------------|-----------------------------------------------------------------|
| LogisticRegression         | C                                         | {0,001, 0,01, 0,1, 1, 10, 100}                                  |
| KNeighborsClassifier       | n_neighbors                               | {1, 3, 5, ..., 31} (ungerade)                                   |
| GaussianNB / BernoulliNB   | —                                         | keine Suche, Standardeinstellungen                              |
| SVC                        | C<br>kernel                               | {0,01, 0,1, 1, 10}<br>rbf (fixiert)                             |
| MLPClassifier              | hidden_layer_sizes<br>alpha               | {(64), (128), (64, 32), (128, 64)}<br>{0,0001, 0,001, 0,01}     |
| RandomForestClassifier     | n_estimators<br>max_depth<br>max_features | {100, 200}<br>{unbegrenzt, 10, 20}<br>{sqrt, log2}              |
| GradientBoostingClassifier | max_iter<br>learning_rate<br>max_depth    | {100, 200, 300}<br>{0,01, 0,05, 0,1}<br>{5, 10, 15, unbegrenzt} |

### A.2. Detaillierte Ergebnistabellen: alle Klassifikatoren

Tabelle 4: Logistic Regression: Ergebnisse je Datensatz. CV-AUC/CV-F1 = 5-fold-CV-Mittelwert ( $\pm$  Std.) ohne Hyperparameter-Suche (Standardeinstellungen); Test-Werte auf separatem Hold-out-Testset.

| Datensatz | CV-AUC            | Test-AUC | CV-F1             | Test-F1 | Test-Acc. |
|-----------|-------------------|----------|-------------------|---------|-----------|
| Telco     | 0,846 $\pm$ 0,013 | 0,842    | 0,592 $\pm$ 0,030 | 0,604   | 80,55 %   |
| Bank      | 0,928 $\pm$ 0,018 | 0,912    | 0,475 $\pm$ 0,028 | 0,629   | 87,76 %   |
| Ecom      | 0,890 $\pm$ 0,014 | 0,902    | 0,497 $\pm$ 0,027 | 0,541   | 88,94 %   |

Tabelle 5: k-Nearest Neighbors: Ergebnisse je Datensatz. CV-AUC = Nested-CV-Mittelwert ( $\pm$  Std.) aus 5 äußeren Folds; F1/P/R bezieht sich auf die Zielklasse (Churn, Subscription, Purchase).

| Datensatz | k  | CV-AUC            | Test-AUC | F1   | Prec. | Recall |
|-----------|----|-------------------|----------|------|-------|--------|
| Telco     | 25 | 0,768 $\pm$ 0,012 | 0,760    | 0,50 | 0,56  | 0,44   |
| Bank      | 27 | 0,768 $\pm$ 0,012 | 0,770    | 0,34 | 0,63  | 0,23   |
| Ecom      | 31 | 0,889 $\pm$ 0,013 | 0,890    | 0,62 | 0,71  | 0,55   |

Tabelle 6: Naive Bayes (BernoulliNB): Ergebnisse je Datensatz. CV-AUC/CV-F1 = 5-fold-CV-Mittelwert ( $\pm$  Std.), keine Hyperparameter-Suche; Test-Werte auf separatem Hold-out-Testset.

| Datensatz | CV-AUC            | Test-AUC | CV-F1             | Test-F1 | Test-Acc. |
|-----------|-------------------|----------|-------------------|---------|-----------|
| Telco     | $0,821 \pm 0,012$ | 0,808    | $0,597 \pm 0,010$ | 0,593   | 69,55 %   |
| Bank      | $0,819 \pm 0,047$ | 0,838    | $0,350 \pm 0,079$ | 0,538   | 81,99 %   |
| Ecom      | $0,812 \pm 0,009$ | 0,830    | $0,484 \pm 0,018$ | 0,508   | 80,25 %   |

Tabelle 7: Support Vector Machine (RBF-Kernel): Ergebnisse je Datensatz. CV-Acc. = 5-fold-CV-Mittelwert (Accuracy-Scoring) des inneren Grid-Search über  $C$ ; F1/P/R für Zielklasse.

| Datensatz | $C$ | CV-Acc. | Test-AUC | F1   | Prec. | Recall |
|-----------|-----|---------|----------|------|-------|--------|
| Telco     | 1   | 0,804   | 0,796    | 0,56 | 0,64  | 0,49   |
| Bank      | 1   | 0,906   | 0,932    | 0,48 | 0,66  | 0,38   |
| Ecom      | 10  | 0,891   | 0,859    | 0,60 | 0,69  | 0,53   |

Tabelle 8: Multi-Layer Perceptron: Ergebnisse je Datensatz. CV-AUC = Nested-CV-Mittelwert ( $\pm$  Std.); Architektur und Regularisierungsparameter  $\alpha$  aus innerem CV-Schritt; F1/P/R für Zielklasse.

| Datensatz | Architektur, $\alpha$ | CV-AUC            | Test-AUC | F1   | Prec. | Recall |
|-----------|-----------------------|-------------------|----------|------|-------|--------|
| Telco     | (64), 0,01            | $0,829 \pm 0,019$ | 0,844    | 0,58 | 0,66  | 0,52   |
| Bank      | (128), 0,01           | $0,938 \pm 0,003$ | 0,941    | 0,55 | 0,63  | 0,49   |
| Ecom      | (128, 64), 0,01       | $0,910 \pm 0,008$ | 0,916    | 0,63 | 0,71  | 0,57   |

Tabelle 9: Random Forest: Ergebnisse je Datensatz. CV-AUC = Nested-CV-Mittelwert ( $\pm$  Std.); Konfiguration = Tiefe / Merkm. / Bäume aus innerem CV-Schritt; F1/P/R für Zielklasse.

| Datensatz | Konfiguration         | CV-AUC            | Test-AUC | F1   | Prec. | Recall |
|-----------|-----------------------|-------------------|----------|------|-------|--------|
| Telco     | 10 / sqrt / 100       | $0,845 \pm 0,010$ | 0,838    | 0,63 | 0,55  | 0,73   |
| Bank      | $\infty$ / sqrt / 200 | $0,945 \pm 0,004$ | 0,943    | 0,51 | 0,65  | 0,43   |
| Ecom      | 20 / log2 / 200       | $0,927 \pm 0,006$ | 0,924    | 0,63 | 0,71  | 0,56   |

Tabelle 10: Gradient-Boosting-Ergebnisse je Datensatz (nested CV und Hold-out-Test). Beste Lernrate / Tiefe / Iterationen: Telco 0,01 / 5 / 300; Bank 0,05 / unbegrenzt / 100; E-Commerce 0,01 / unbegrenzt / 300.

| Datensatz | Split    | Nested-CV ROC-AUC | Test ROC-AUC | Test F1 |
|-----------|----------|-------------------|--------------|---------|
| Telco     | random   | $0.848 \pm 0.010$ | 0.845        | 0.581   |
| Bank      | temporal | $0.945 \pm 0.014$ | 0.914        | 0.621   |
| Ecom      | random   | $0.932 \pm 0.005$ | 0.935        | 0.658   |